



Features del MLP vs Heurística

Proyecto Scheduling con IA

Este documento describe las **características (features)** que utiliza cada método de asignación de turnos: la **Heurística Greedy** y la **Red Neuronal MLP (Multi-Layer Perceptron)**.

Heurística Greedy — Criterios de Decisión

La heurística **NO usa features numéricas**. En su lugar, aplica **reglas determinísticas** en orden de prioridad:

#	CRITERIO	DESCRIPCIÓN	TIPO
1	Disponibilidad	¿El empleado trabaja ese día y horario?	Filtro binario (sí/no)
2	Horas restantes	¿Puede trabajar 5h más sin exceder su máximo semanal?	Filtro binario (sí/no)
3	Un turno por día	¿Ya fue asignado a otro turno ese mismo día?	Filtro binario (sí/no)
4	Menor carga	Entre los candidatos válidos, elige al que tenga menos horas acumuladas	Ordenamiento

Flujo de la Heurística:

Para cada turno (en orden T1, T2, ..., T8):

1. Filtrar empleados disponibles en ese día/horario
2. Filtrar los que no exceden horas máximas
3. Filtrar los que no trabajan ya ese día

4. Ordenar por horas acumuladas (ascendente)
5. Asignar los primeros N empleados ($N = \text{requeridos}$)

Ventajas

- ✓ Rápido ($O(n \cdot m)$ donde $n = \text{turnos}$, $m = \text{empleados}$)
- ✓ Determinístico (siempre da el mismo resultado)
- ✓ Fácil de implementar y entender

Limitaciones

- ✗ **Miope:** Solo ve el turno actual, no planifica a futuro
- ✗ No optimiza globalmente (puede dejar turnos sin cubrir al final)
- ✗ El orden de procesamiento de turnos afecta el resultado



Red Neuronal MLP — Features de Entrada

El MLP recibe un **vector de 10 features numéricas** por cada par (empleado, turno) y predice la **probabilidad de asignación** (0.0 a 1.0).

Vector de 10 Features:

#	FEATURE	FÓRMULA	RANGO	DESCRIPCIÓN
0	horas_max_norm	<code>horas_max_semana / 40</code>	[0, 1.2]	Capacidad máxima del empleado normalizada
1	horas_asignadas	<code>horas_acumuladas / 40</code>	[0, 1.2]	Cuántas horas ya lleva asignadas
2	horas_restantes	<code>max(0, max - asignadas) / 40</code>	[0, 1.2]	Cuántas horas más puede trabajar
3	disponible	<code>esta_disponible(emp, turno)</code>	{0, 1}	¿Puede trabajar ese día/horario?

#	FEATURE	FÓRMULA	RANGO	DESCRIPCIÓN
4	dia_norm	$\text{DIAS_MAP}[\text{dia}] / 6$	[0, 1]	Día de la semana codificado (Lun=0, Dom=1)
5	horario_norm	$\text{HORARIOS_MAP}[\text{horario}] / 2$	[0, 0.5, 1]	Franja horaria (Mañana=0, Tarde=0.5, Completo=1)
6	emp_requeridos	$\text{turno.requeridos} / 3$	[0, 1]	Cuántos empleados necesita el turno
7	ya_trabaja_dia	1 si ya asignado ese día	{0, 1}	¿Ya tiene un turno ese día?
8	ratio_uso	$\text{asignadas} / \text{max}$	[0, 1]	Porcentaje de capacidad

#	FEATURE	FÓRMULA	RANGO	DESCRIPCIÓN
				utilizada
9	dias_disponibles	<code>len(disponibilidad) / 7</code>	[0, 1]	Flexibilidad del empleado

Arquitectura del MLP:

```
Input(10) → Dense(64, ReLU) → Dense(32, ReLU) → Dense(16, ReLU) → Dense(1, Sigmoid)
```

CAPA	NEURONAS	ACTIVACIÓN	PARÁMETROS
Entrada	10	—	—
Oculto 1	64	ReLU	704 (10×64 + 64 bias)
Oculto 2	32	ReLU	2,080 (64×32 + 32 bias)

CAPA	NEURONAS	ACTIVACIÓN	PARÁMETROS
Ocultas 3	16	ReLU	528 (32×16 + 16 bias)
Salida	1	Sigmoid	17 (16×1 + 1 bias)
Total			3,329 parámetros

Hiperparámetros:

PARÁMETRO	VALOR	JUSTIFICACIÓN
Épocas	50	Suma de pasos de entrenamiento y validación suficientes para converger
Batch Size	32	Balance entre velocidad y estabilidad

Funciones de Activación:

FUNCIÓN	FÓRMULA	DÓNDE SE USA
ReLU	$f(x) = \max(0, x)$	Capas ocultas
Sigmoid	$f(x) = \frac{1}{1+e^{-x}}$	Capa de salida

PARÁMETRO	VALOR	JUSTIFICACIÓN
		es un grafo
Optimizador	Adam (lr=0.001)	Adaptativo de aprendizaje por
Loss	Binary Crossentropy	Es la clase binaria
Train/Val Split	80% / 20%	Validación por
Dataset	20,000 muestras	50% de los datos

FUNCIÓN	FÓRMULA	DÓNDE SE USA
Tanh	$f(x) = \tanh(x)$	No usada

Ventajas del MLP

- ✓ Aprende patrones complejos no lineales
- ✓ Generaliza a combinaciones no vistas en entrenamiento
- ✓ Puede mejorar con más datos

Limitaciones del MLP

- ✗ Requiere dataset de entrenamiento (generado sintéticamente)
- ✗ Mayor costo computacional
- ✗ Puede sobreajustar con pocos datos



Comparación Directa

ASPECTO	HEURÍSTICA	MLP
Entradas	Reglas fijas	10 features numéricas
Decisión	Determinística, secuencial	Probabilística, paralela
Aprendizaje	No aprende	Aprende de datos
Velocidad	Instantánea	Requiere entrenamiento previo
Adaptabilidad	Rígida	Se adapta a nuevos patrones
Optimalidad	Local (greedy)	Puede acercarse a global
Interpretabilidad	Alta (reglas claras)	Baja (caja negra)
Escalabilidad	Buena	Excelente con más datos

Proyecto Integrador — IA Moderna Aplicada al Scheduling

TensorFlow/Keras • Python • Flask