

Flujo Matemático y Entrenamiento

Desde los datos crudos hasta el Descenso del Gradiente

1 Simulación Monte Carlo y Vectorización

Los datos crudos de este problema consisten en 5 empleados y 8 turnos. Esto produce apenas 40 pares posibles. Una red neuronal no puede converger con un volumen tan bajo de muestras si se busca viabilidad en un entorno de producción. Para solucionar esta limitación técnica y escalar el modelo, el método `generar_dataset(500)` inyecta ruido aleatorio en la heurística base para simular 500 escenarios alternativos de la asignación

Input Vector (X) :

```
$X_i = [1.0, 0.37, 0.62, 1.0,  
0.0, 0.5, 0.66, 0.0, 0.37,  
0.71]$
```

Label (y) :

```
$y_i = 1.0$
```

Matriz Final (X_train) :

semanal. Esto escala el conjunto de datos a **20,000 muestras** (500 soluciones $\times$ 40 pares).

Cada par empleado-turno se vectoriza desde texto plano a un **Tensor** unidimensional de 10 características continuas $\in [0, 1]$. La etiqueta real (Ground Truth) se establece como $y = 1$ si en esa simulación específica el empleado fue asignado, y $y = 0$ en caso contrario.

$16,000 \times 10$ (Filas $\times$ Features)

2

Partición 80/20 y Arquitectura de Capas

Partición Estática

El algoritmo ejecuta una partición estricta de las 20,000 muestras: **80% (16,000)** se destinan a la optimización de pesos (Entrenamiento) y el **20% (4,000)** restante se mantiene oculto para validar la

Arquitectura Keras:

L_1 : 10×64 pesos + 64 sesgos
 L_2 : 64×32 pesos + 32 sesgos

capacidad de generalización del modelo (Validación).

Funciones de Activación

Capas Ocultas (ReLU): Las capas densas de 64, 32 y 16 neuronas implementan la función de activación Rectified Linear Unit. Matemáticamente definida como $f(x) = \max(0, x)$. Esta función trunca los valores negativos a cero, introduciendo no-linealidad estricta en el sistema y previniendo el problema del desvanecimiento del gradiente inherente a redes profundas.

Capa de Salida (Sigmoide): Proyecta la combinación lineal final hacia un rango continuo entre 0 y 1. Definida como $S(x) = \frac{1}{1 + e^{-x}}$. De este modo, la salida de la red es directamente interpretable como la **probabilidad** matemática de asignación del empleado.

$L_3: 32 \times 16$ pesos + 16 sesgos
 $L_{out}: 16 \times 1$ pesos + 1 sesgo

Parámetros Entrenables

Totales: 3,329

3

El Motor: Loss, Gradiente y Optimización

Cálculo de la Función de Costo (Loss)

Dado que es un problema de clasificación binaria, se implementa la función de costo `binary_crossentropy` (Entropía Cruzada Binaria). Esta métrica cuantifica la divergencia estadística entre la distribución de probabilidad inferida por el modelo y las etiquetas reales. Castiga exponencialmente las predicciones con alta confianza que resultan incorrectas.

$$Loss = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Descenso del Gradiente y Optimizador Adam

El algoritmo calcula los gradientes mediante derivadas parciales de la función de pérdida respecto a cada uno de los 3,329 pesos de la arquitectura (Backpropagation). Este vector gradiente establece la dirección matemática exacta para minimizar el error topológico. Se utiliza el

LOSS FINAL (TRAIN)

0.0959

VAL LOSS (EXAMEN)

0.0971

* Los registros reales del modelo evidencian una convergencia matemática sólida. La métrica de error disminuyó de 0.22 a 0.09 a lo largo de 50 épocas de entrenamiento.

optimizador Adam (Adaptive Moment Estimation), el cual calcula tasas de aprendizaje adaptativas para cada parámetro de forma independiente, garantizando una convergencia rápida hacia el objetivo y evitando el estancamiento en mínimos locales.

4 Métricas y Detección de Overfitting

Cálculo de Exactitud (Accuracy)

La exactitud (Accuracy) es una métrica de interpretación humana, no el objetivo directo de la optimización matemática. Una vez que la capa de salida sigmoide genera un valor continuo (ej. $\hat{y} = 0.82$), se aplica un umbral de decisión rígido, estandarizado en 0.5 . Para toda predicción donde $\hat{y} \geq 0.5$, la salida de red se clasifica

ACCURACY (TRAIN)

94.21%

VAL ACCURACY

93.90%

binariamente como \$1\$. Si la etiqueta real de dicha muestra (Ground Truth) era efectivamente \$1\$, se contabiliza como un Verdadero Positivo. La métrica final representa estrictamente la proporción de clasificaciones correctas sobre la cardinalidad total del lote analizado.

Detección de Sobreajuste (Overfitting)

El fenómeno de sobreajuste se presenta cuando la red neuronal pierde su capacidad de generalización y comienza a memorizar el ruido específico del conjunto de entrenamiento. La detección de esta anomalía técnica se realiza analizando la divergencia en la gráfica cartesiana entre la pérdida de entrenamiento ($Loss$) y la pérdida de validación (val_Loss).

- Si ambas funciones descienden simétricamente, el modelo **aprende patrones subyacentes**.
- Si $Loss$ desciende pero val_Loss presenta tendencia al alza o rebote, el sistema

* El análisis de los archivos generados indica que la métrica $Val Loss$ desciende de forma estable hasta la época ~22, para posteriormente oscilar en el rango de 0.095 a 0.098. Esto determina empíricamente que 50 épocas representan el límite de capacidad de esta iteración; continuar el entrenamiento resultaría en sobreajuste directo.

está sobreajustando.

5 Evaluación Estricta de Negocio en Producción

Tras la inferencia probabilística del modelo, el módulo predictivo ejecuta la discretización final imponiendo el cumplimiento estricto de las reglas operativas y restricciones duras de negocio requeridas. Inmediatamente después, interviene el proceso de evaluación de viabilidad. Esta fase descarta deliberadamente el rendimiento estadístico interno de la red neuronal (Accuracy/Loss) para cuantificar de forma rigurosa exclusivamente los **KPIs Operativos de Negocio** que determinan la utilidad real del producto final:

- Cobertura Total (Aseguramiento de los 8 turnos requeridos).
- Utilización de Horas (Impacto directo en el costo financiero).
- Desviación Estándar de Horas (Distribución equitativa y riesgo de fatiga de la plantilla).